

HDT # 5 - Orquestación

Preguntas

- ¿Qué arquitectura/arquitecturas resuelven mejor este problema? ¿Por qué?
 - La Arquitectura Centralizada ya que es muy eficiente porque mantiene el estado global de la conversación en un solo lugar y dispara sub-tareas específicas. Por otro lado, la Arquitectura Descentralizada es la más óptima y escalable ya que al utilizar handoffs, cada agente carga únicamente con su propio contexto y herramientas. Esto es mejor que la centralizada y la jerárquica porque evita que se pierda el contexto cuando el supervisor tiene que re-escribir y reenviar el contexto hacia abajo en la cadena. En la descentralizada, el Agente FAQ atiende directamente y si necesita pasar al experto del Clima simplemente le cede el canal directo con el usuario.
- ¿Considera que es necesario utilizar un sistema multiagente en este caso? ¿Por qué?
 - No es estrictamente necesario, el problema actual se puede resolver de forma óptima con un solo agente monolítico utilizando function calling simple. Un sistema multiagente estructurado con supervisor y workers o con redes de handoffs aporta beneficios reales únicamente cuando los subdominios de la empresa requieren prompts inmensos que sobrepasan la ventana de contexto del LLM o cuando diferentes partes del sistema requieren distintos modelos especializados. Para tareas de consulta simple segmentarlo en múltiples agentes añade latencia y complejidad adicional sin ser absolutamente necesario para su correcto funcionamiento.